

Sprawozdanie z projektu

„Wpływ warunków pogodowych na rynek energii elektrycznej w Polsce”

Dubois Jozef, Gajda Stefan (Neandertalczycy SQLa)

1 Tematyka i cel biznesowy

Celem projektu jest zaprojektowanie hurtowni danych oraz warstwy raportowej pozwalającej analizować wpływ warunków pogodowych na pracę systemu elektroenergetycznego w Polsce. System integruje dane pogodowe, dane o produkcji energii przez jednostki wytwórcze oraz dane ogólnokrajowe dotyczące cen, bilansu i zapotrzebowania na energię elektryczną. Rozwiązanie umożliwia analizę zależności między temperaturą, wiatrem, opadami, ciśnieniem i innymi parametrami pogodowymi a obciążeniem KSE, produkcją elektrowni oraz cenami energii.

Cel biznesowy:

- identyfikacja czynników pogodowych wpływających na zmienność zapotrzebowania na energię elektryczną,
- analiza zależności między warunkami pogodowymi a produkcją poszczególnych elektrowni,
- porównanie prognozowanego i rzeczywistego obciążenia krajowego systemu elektroenergetycznego,
- monitorowanie cen energii i ich powiązania z bilansem mocy oraz pogodą,
- wsparcie analityków w ocenie sezonowości, ryzyka pogodowego i odchyłeń od typowego profilu pracy systemu.

Planowane korzyści z perspektywy odbiorcy rozwiązania:

- szybszy dostęp do zintegrowanych danych z wielu źródeł w jednym modelu hurtowni,
- możliwość porównywania danych pogodowych, produkcyjnych i cenowych w tej samej granularności czasowej,
- lepsze zrozumienie wpływu ekstremalnych temperatur, wiatru lub opadów na zużycie i ceny energii,
- łatwiejsze przygotowanie raportów dla kierownictwa, analityków rynku energii oraz zespołów planowania produkcji,
- ograniczenie ręcznej pracy związanej z pobieraniem, czyszczeniem i łączeniem danych z API.

Odbiorcy rozwiązania:

- analitycy rynku energii,
- operatorzy i jednostki planujące pracę systemu elektroenergetycznego,
- zespoły odpowiedzialne za prognozowanie zapotrzebowania i analizę cen,
- osoby przygotowujące raporty zarządcze i operacyjne dotyczące rynku energii.

2 Źródła danych

W rozwiązaniu wykorzystywane są dwa źródła pobierane cyklicznie przez API (PSE oraz Meteostat) oraz jedno źródło referencyjne w postaci kuratorowanego pliku CSV z metadanymi elektrowni. Lista jednostek wytwórczych pochodzi z PSE; ich atrybuty opisowe (kategoria, moc, lokalizacja, województwo) są utrzymywane w pliku `powerplant_meta.csv`.

2.1 Dane energetyczne - PSE API

- Źródło: <https://api.raporty.pse.pl/api/>
- Wykorzystywane obszary danych:
 - `gen-jw` - dane o generacji jednostek wytwórczych (oraz lista elektrowni),
 - `energy-prices` - dane cenowe i bilansowe,
 - `rce-pln` - rynkowa cena energii,
 - `kse-load` - prognozowane i rzeczywiste zapotrzebowanie KSE.
- Format danych: odpowiedzi REST w formacie JSON, z obsługą paginacji (pole `nextLink`).
- Częstotliwość odświeżania: dziennie, dla zamkniętego okna dat (domyślnie od dwóch miesięcy wstecz do dnia poprzedniego).
- Docelowe tabele: `FactPowerPlantOutput`, `FactPolandEnergy` oraz lista elektrowni do `DimPowerPlant`.

2.2 Metadane elektrowni - plik `powerplant_meta.csv`

- Źródło: kuratorowany plik CSV utrzymywany w repozytorium projektu.
- Zakres danych: nazwa elektrowni (klucz biznesowy), kategoria/rodzaj paliwa, moc zainstalowana w MW, współrzędne geograficzne, województwo.
- Pochodzenie: plik został zbudowany jednorazowo na podstawie publicznych rejestrów jednostek wytwórczych oraz geokodowania nazw (m.in. usługa Nominatim; wynik zapisany w `geo_cache.json`). W bieżącym, cyklicznym procesie ETL nie są wykonywane zapytania do GPI/TGE ani Nominatim - dane czerpane są z pliku CSV.
- Częstotliwość aktualizacji: rzadko, ręcznie - po pojawieniu się nowej jednostki w danych PSE lub po zmianie atrybutów elektrowni.
- Docelowa tabela: `DimPowerPlant` (obsługa historii zmian mechanizmem SCD typu 2).

2.3 Dane pogodowe - Meteostat API

- Źródło: meteostat.p.rapidapi.com/point/hourly (dostęp przez RapidAPI, klucz w zmiennej środowiskowej `RAPIDAPI_KEY`).
- Zakres danych (realnie ładowany): temperatura, punkt rosy, wilgotność względna, opady, kierunek i prędkość wiatru, ciśnienie, kod zjawiska pogodowego.
- Format danych: odpowiedź REST w formacie JSON.

- Granularność: dane godzinowe dla punktu określonego współrzędnymi elektrowni; pobierane w oknach do 30 dni.
- Częstotliwość odświeżania: dziennie. Uwaga: dostawca publikuje dane stacji z kilkudniowym opóźnieniem, co jest uwzględnione w kontroli jakości.
- Docelowa tabela: **FactWeather**.

2.4 Zestawienie źródeł danych

Źródło	Dane	Format	Odświeżanie	Zastosowanie w modelu
PSE API	produkcja, ceny, bilans, zapotrzebowanie, lista jednostek	JSON/REST	dziennie (okno dat)	zasilenie FactPowerPlantOutput i FactPolandEnergy oraz lista elektrowni
powerplant_meta .csv	kategoria, moc, współrzędne, województwo	CSV	rzadko / ręcznie	atributy i SCD2 w DimPowerPlant
Meteostat API	pogoda godzinowa dla punktu	JSON/REST	dziennie (z lagiem źródła)	zasilenie FactWeather dla lokalizacji elektrowni

Table 1: Źródła danych wykorzystywane w projekcie

3 Analiza źródeł danych

3.1 Harmonogram odświeżania

- Jednorazowe pobranie danych historycznych z PSE oraz danych pogodowych dla wybranego zakresu czasu; jednorazowe wygenerowanie wymiaru czasu.
- Cykliczne (dziennie) przeładowanie zamkniętego okna dat - domyślnie od dwóch miesięcy wstecz do dnia poprzedniego, bez dnia bieżącego.
- Dane pogodowe z Meteostat są pobierane dla współrzędnych aktywnych elektrowni odczytanych z **DimPowerPlant**.

3.2 Identyfikowane problemy

- różne formaty i nazwy pól w źródłach danych,
- konieczność synchronizacji danych czasowych z wielu endpointów PSE,
- różne granularności danych: krajowa dla cen i obciążenia, jednostkowa dla produkcji elektrowni oraz punktowa dla pogody,
- konieczność mapowania nazw jednostek wytwórczych z PSE do wymiaru elektrowni,
- obsługa zmiany czasu letniego i zimowego, czyli godzin brakujących oraz godzin zduplikowanych,

- potrzeba utrzymania historii zmian atrybutów elektrowni, np. kategorii lub mocy zainstalowanej,
- obsługa paginacji odpowiedzi PSE API,
- kilkudniowe opóźnienie publikacji danych pogodowych przez Meteostat.

3.3 Niezbędne transformacje

- ujednolicenie formatów dat i czasu do jednego standardu używanego w hurtowni,
- wygenerowanie wymiaru czasu z atrybutami roku, kwartału, miesiąca, tygodnia, dnia, godziny i kwadransa,
- oznaczenie dni weekendowych oraz dni zmiany czasu za pomocą pól `isWeekend`, `isExtraHourDay`, `isExtraHour`, `isMissingHourDay` i `isMissingHour`,
- agregacja produkcji po jednostkach wytwórczych do ziarna elektrowni w tabeli `FactPowerPlantOutput`,
- agregacja danych krajowych do kwadransa: średnia dla miar cenowych i zapotrzebowania, suma dla bilansu mocy,
- lookup kluczy obcych `TimeId` i `PowerPlantId`,
- obsługa historii zmian elektrowni mechanizmem SCD typu 2.

4 Architektura rozwiązania

System zaprojektowano w architekturze warstwowej. Trzon stanowi hurtownia danych w Microsoft SQL Server. Ekstrakcja i transformacja danych ze źródeł realizowana jest skryptami w języku Python, które zapisują dane do warstwy staging; ładowanie z warstwy staging do modelu wymiarowego (z obsługą SCD2 i lookupów kluczy) wykonują pakiety SSIS. Po przetworzeniu dane są wykorzystywane w raportach Power BI.

4.1 Warstwa źródłowa

Warstwa źródłowa obejmuje API PSE (zapotrzebowanie, ceny, bilans, produkcja oraz lista jednostek), API Meteostat (dane pogodowe) oraz plik referencyjny `powerplant_meta.csv` (atrybuty elektrowni: kategoria, moc, współrzędne, województwo).

4.2 Warstwa staging

Warstwa staging (schemat `stg`) przechowuje dane pobrane i wstępnie przekształcone przez skrypty Python. Każdy bieg dla zadanego okna dat wykonuje pełne odświeżenie tabel staging (`TRUNCATE + ponowny zapis`), dzięki czemu warstwa zawsze odzwierciedla bieżący, spójny zakres danych. Wstawianie realizowane jest wsadowo (`fast_executemany`). Tabele staging nie przechowują kolumn audytowych - rolę kontroli jakości pełnią dedykowane skrypty SQL (sekcja 6.7).




Figure 1: Architektura zaimplementowanego rozwiązania

4.3 Warstwa ładowania (SSIS)

- Technologia: SSIS oraz procedury/transformacje SQL w Microsoft SQL Server.
- Funkcje: uruchomienie właściwego skryptu ekstrakcji (Execute Process Task), ładowanie wymiarów (w tym SCD2 elektrowni), lookup kluczy obcych `TimeId` i `PowerPlantId`, ładowanie tabel faktów oraz obsługa godziny zdublowanej przy zmianie czasu.
- Tryby: ładowanie historyczne dla wybranego okna oraz cykliczne przeładowanie okna bieżącego; orkiestracja przez pakiet `Master.dtsx` lub orkiestrator Pythonowy `load_range.py`.

4.4 Warstwa hurtowni danych

- Technologia: Microsoft SQL Server.
- Model danych: schemat konstelacji faktów, w którym kilka tabel faktów współdzieli te same wymiary.
- Główne wymiary: `DimTime`, `DimPowerPlant`.
- Główne tabele faktów: `FactWeather`, `FactPowerPlantOutput`, `FactPolandEnergy`.
- Indeksy: indeksy nieklastrowane na kluczach obcych faktów (`TimeId`, `PowerPlantId`) przyspieszające łączenia w raportach.

4.5 Warstwa raportowa

- Technologia: Power BI (plik `business.pbix`).
- Tryb wykorzystania danych: model analityczny zasilany z hurtowni SQL Server (import), z relacjami między wymiarami a tabelami faktów odwzorowującymi konstelację faktów.
- Zaimplementowane funkcje: siedem stron raportu (Przegląd, Rynek i bilansowanie, Pogoda a produkcja, Ceny i bilans, Wzorce czasowe, Geografia i moce, Pogoda a moc (kosze)) z analizą przekrojową według czasu, elektrowni, kategorii i województwa; wizualizacje trendów godzinowych, dziennych i sezonowych; mapy elektrowni i województw (warstwa GeoJSON); fragmentatory (slicery) po zakresie dat i kategorii elektrowni.
- Autorskie miary DAX, m.in. Współczynnik wykorzystania (Capacity Utilization), Błąd prognozy (MW) (Forecast Error), Moc floty oraz Średnia moc w przekroju kraju i województwa.

5 Model hurtowni danych

Model hurtowni danych składa się z dwóch tabel wymiarów i trzech tabel faktów. Model ma charakter konstelacji faktów, ponieważ tabele **FactWeather**, **FactPowerPlantOutput** i **FactPolandEnergy** współdzielą wymiar czasu, a dwie pierwsze dodatkowo współdzielą wymiar elektrowni.




Figure 2: Logiczny diagram relacji w modelu hurtowni danych

5.1 Opis tabel modelu

Tabela	Typ	Ziarno	Opis
DimTime	wymiar	jeden rekord dla kwadransa	Wymiar czasu zawierający datę, godzinę, kwadrans, elementy kalendarza oraz flagi weekendu i zmiany czasu.
DimPowerPlant	wymiar SCD2	jedna wersja rekordu elektrowni	Wymiar elektrowni z nazwą, kategorią, współrzędnymi, województwem, mocą zainstalowaną oraz zakresem ważności rekordu.
FactWeather	fakt	godzina × elektrownia	Dane pogodowe dla lokalizacji elektrowni pobrane z Meteostat, powiązane z czasem i elektrownią.
FactPowerPlantOutput	fakt	kwadrans × elektrownia	Produkcja energii przez elektrownię w danym kwadransie.
FactPolandEnergy	fakt	kwadrans dla Polski	Dane ogólnokrajowe: ceny, bilans mocy oraz prognozowane i rzeczywiste zapotrzebowanie.

Table 2: Tabele w modelu hurtowni danych

5.2 Tabela DimTime

Tabela **DimTime** jest wspólnym wymiarem czasu dla wszystkich tabel faktów. Pozwala prowadzić analizy w przekroju roku, kwartału, miesiąca, tygodnia, dnia, godziny oraz kwadransa. Kluczem głównym jest **TimeId** typu **BIGINT**. Wymiar jest generowany jednorazowo skryptem **DimTimeLoader.py** dla pełnego zakresu analizy (2024-2027) i ładowany pakietem **Load_DimTime**.

Identyfikator czasu ma format **YYYYMMDDHHmmX**, gdzie **mm** oznacza minutę kwadransa (00, 15, 30 lub 45), a **X** jest bitem informującym, czy rekord dotyczy zdublowanej godziny przy jesiennej zmianie czasu. Dzięki temu proces ETL jednoznacznie rozróżnia godziny normalne, brakujące i zdublowane.

Kolumna	Typ danych	Znaczenie
TimeId	BIGINT	klucz główny wymiaru czasu (13-cyfrowy, deterministyczny)
timestamp	DATETIME	pełna data i godzina wraz z minutami
year, quarter_year, month, week, day, hour, quarter_hour	INT/TINYINT	atrybuty kalendarzowe używane do agregacji i filtrowania
dayOfWeek, isWeekend	TINYINT/BIT	dzień tygodnia i oznaczenie weekendu
isExtraHourDay, isExtraHour, isMissingHourDay, isMissingHour	BIT	obsługa zmiany czasu letniego i zimowego

Table 3: Najważniejsze kolumny tabeli DimTime

5.3 Tabela DimPowerPlant

Tabela DimPowerPlant opisuje elektrownie oraz ich cechy. Wymiar jest wolnozmienny i obsługiwany jako SCD typu 2, ponieważ wybrane cechy elektrowni (przede wszystkim kategoria, moc zainstalowana oraz korekty lokalizacyjne) mogą zmieniać się w czasie.

Kolumna	Typ danych	Znaczenie
PowerPlantId	INT	klucz główny (IDENTITY) wymiaru elektrowni
PowerPlantName	VARCHAR(100)	nazwa elektrowni, traktowana jako klucz biznesowy
category	VARCHAR(100)	kategoria lub rodzaj paliwa podstawowego
latitude, longitude	DECIMAL(9,6)	współrzędne geograficzne wykorzystywane do pobierania pogody
voivodeship	VARCHAR(100)	województwo, przydatne w raportach regionalnych
validFrom, validTo, isValid	BIGINT/BIT	poła obsługujące historię zmian w SCD typu 2 (validFrom/validTo jako TimeId)
installed_power	INT	moc zainstalowana lub osiągalna w MW
record_creation_date	BIGINT	znacznik utworzenia rekordu w procesie ETL

Table 4: Najważniejsze kolumny tabeli DimPowerPlant

5.4 Tabela FactWeather

Tabela FactWeather przechowuje dane pogodowe dla lokalizacji elektrowni. Każdy rekord jest powiązany z konkretną elektrownią i godziną, co pozwala analizować wpływ warunków pogodowych w lokalizacji elektrowni na produkcję oraz pośrednio na zapotrzebowanie i ceny.

Kolumna	Typ danych	Znaczenie
FactWeatherId	BIGINT	techniczny klucz główny tabeli faktów
PowerPlantId	INT	klucz obcy do DimPowerPlant
TimeId	BIGINT	klucz obcy do DimTime
temp, dew_point, relative_humidity_pct	DECIMAL(4,1)	temperatura, punkt rosy, wilgotność względna
precipitation	DECIMAL(4,1)	opady
wind_direction, wind_speed	DECIMAL(4,1)	kierunek i prędkość wiatru
pressure	DECIMAL(6,1)	ciśnienie atmosferyczne
weather_code	INT	kod zjawiska pogodowego

Table 5: Kolumny tabeli FactWeather

5.5 Tabela FactPowerPlantOutput

Tabela FactPowerPlantOutput zawiera produkcję elektrowni w danym kwadransie. Ziarno tabeli to elektrownia i czas. Miara Power informuje o wielkości generacji, którą można porównywać z mocą zainstalowaną z wymiaru elektrowni oraz z warunkami pogodowymi z tabeli FactWeather.

Kolumna	Typ danych	Znaczenie
FactPowerId	BIGINT	techniczny klucz główny tabeli faktów
PowerPlantId	INT	klucz obcy do wymiaru elektrowni
TimeId	BIGINT	klucz obcy do wymiaru czasu
Power	FLOAT	produkcja elektrowni w danym kwadransie

Table 6: Kolumny tabeli FactPowerPlantOutput

5.6 Tabela FactPolandEnergy

Tabela FactPolandEnergy przechowuje dane ogólnokrajowe w ziarnie kwadransu. Nie posiada klucza do wymiaru elektrowni, ponieważ są to dane ogólnopolskie. Dane służą do analizy obciążenia KSE, cen energii, bilansu mocy oraz jakości prognozy zapotrzebowania.

Kolumna	Typ danych	Znaczenie
FactNationwideDataId	BIGINT	techniczny klucz główny tabeli faktów
TimeId	BIGINT	klucz obcy do wymiaru czasu
cen_cost, cor_cost, ceb_sr_cost, sk_cost_power	DECIMAL(16,4)	miary cenowe i kosztowe z danych PSE
cdsac_cost	DECIMAL(16,4)	cena energii z rynku Single Day-Ahead Coupling, w PLN/MWh
balance_power	DECIMAL(16,4)	bilans mocy systemu (wartości dodatnie - nadwyżka, ujemne - deficyt)
rce_cost	DECIMAL(16,4)	rynkowa cena energii w PLN
load_fcst, load_actual	DECIMAL(16,4)	prognozowane i rzeczywiste zapotrzebowanie krajowe

Table 7: Kolumny tabeli FactPolandEnergy

6 Proces ETL

Proces ETL jest kluczowym elementem projektu - dane pochodzą z kilku źródeł o różnym formacie i granularności i muszą zostać sprowadzone do wspólnego ziarna czasowego. Został zrealizowany jako hybryda: **ekstrakcję i transformację** wykonują skrypty w języku Python (biblioteki `requests`, `pandas`, `pyodbc`), które zapisują wynik do warstwy staging; **ładowanie** z warstwy staging do modelu wymiarowego (SCD2, lookupy, obsługa zmiany czasu) wykonują pakiety SSIS.

6.1 Ekstrakcja i transformacja (Python)

Każdy skrypt obsługuje paginację PSE oraz parametryzowany zakres dat (`DATE_FROM`, `DATE_TO`, `LOOKBACK_DAYS`); połączenie z bazą jest czytane ze zmiennych środowiskowych (`POWERDWH_SERVER`, `POWERDWH_DATABASE`) z domyślnymi wartościami `localhost/PowerDWH`.

- `extract_powerplant.py` - pobiera listę elektrowni z endpointu `gen-jw`, łączy ją z metadanymi z `powerplant_meta.csv` (kategoria, moc, współrzędne, województwo) i zapisuje do `stg.PowerPlant`.
- `extract_poland_energy.py` - pobiera `energy-prices`, `rce-pln` i `kse-load`, wyznacza początek slotu (`datetime` pomniejszony o 15 minut), agreguje do kwadransa (średnia miar, suma dla `balance_power`) i zapisuje do `stg.PolandEnergy`.
- `extract_power_output.py` - pobiera generację jednostek z `gen-jw` i zapisuje do `stg.PowerPlantOutput`.
- `extract_weather.py` - odczytuje współrzędne aktywnych elektrowni z `DimPowerPlant`, pobiera dane godzinowe z Meteostat w oknach do 30 dni i zapisuje do `stg.Weather` (wymaga `RAPIDAPI_KEY`).
- `DimTimeLoader.py` - generuje plik `DimTime.csv` (kalendarz kwadransowy 2024-2027 z flagami zmiany czasu); uruchamiany jednorazowo.

6.2 Warstwa staging

Skrypty Python ładują dane do tabel schematu `stg` (`PowerPlant`, `PolandEnergy`, `PowerPlantOutput`, `Weather`). Każdy bieg wykonuje `TRUNCATE` i ponowny zapis całego okna dat, co gwarantuje spójny i powtarzalny zakres wejściowy dla warstwy ładowania.

6.3 Ładowanie wymiarów (SSIS + SQL)

- `Load_DimTime`: ładuje wygenerowany plik `DimTime.csv` (Flat File) do `dbo.DimTime`. Wymiar jest statyczny (2024-2027), więc krok wykonywany jest jednorazowo.
- `Load_DimPowerPlant`: uruchamia `extract_powerplant.py` (Execute Process Task), a następnie wywołuje procedurę `etl.usp_Load_DimPowerPlant` realizującą SCD typu 2 - nowa elektrownia powoduje dodanie rekordu, a zmiana kategorii lub mocy zamyka starą wersję (`validTo`, `isValid=0`) i tworzy nową.

6.4 Ładowanie tabel faktów (SSIS)

Każdy pakiet faktów najpierw uruchamia odpowiedni skrypt ekstrakcji (Execute Process Task), a następnie w Data Flow wykonuje lookup kluczy i ładuje tabelę:

- `Load_FactPolandEnergy`: lookup `TimeId`, ładowanie miar krajowych.
- `Load_FactPowerPlantOutput`: lookup `TimeId` oraz `PowerPlantId`; elektrownie bez dopasowania w wymiarze są pomijane (kontrolowane w QA).
- `Load_FactWeather`: lookup `TimeId` oraz `PowerPlantId`, ładowanie miar pogodowych.

6.5 Obsługa zmiany czasu (DST)

PSE oznacza drugą, zdublowaną godzinę przy jesiennej zmianie czasu literą 'a' doklejaną do `dttime`. Skrypty Python wykrywają ten marker i ustawiają bit `isExtraHour` w tabelach staging, grupując dane po (`slot`, `isExtraHour`), aby nie sklejać dwóch kopii godziny. W wymiarze `DimTime` zdublowana godzina ma własny rekord (bit X na końcu `TimeId`). W pakietach SSIS klucz czasu jest „solony” wyrażeniem `DATEADD(SECOND, isExtraHour, ts)` po obu stronach lookupu, dzięki czemu wiersz dla godziny dodatkowej trafia na swój własny `TimeId`, a klucze pozostają unikalne. Godziny brakujące przy wiosennej zmianie czasu są oznaczone flagami `isMissingHourDay/isMissingHour`.

6.6 Orkiestracja i parametryzacja

- `Master.dtsx` orkiestruje pakiety SSIS: `Load_DimPowerPlant`, a po jego sukcesie - równolegle `Load_FactPolandEnergy`, `Load_FactPowerPlantOutput` i `Load_FactWeather`.
- `load_range.py` jest orkiestratorem Pythonowym dla zadanego zakresu dat (domyślnie od dwóch miesięcy wstecz do dnia poprzedniego). Uruchamia skrypty ekstrakcji oraz pakiety SSIS przez `dtexec` w poprawnej kolejności zależności (m.in. `DimPowerPlant` przed pobraniem pogody, która czyta współrzędne z wymiaru). Obsługuje tryby `range`, `incremental` (kroczące okno dla zadań cyklicznych) i `backfill` (historia). Codzienne uruchomienie zapewnia zadanie Harmonogramu zadań Windows (`run_etl.ps1`).
- **Audyt biegów**: orkiestrator loguje każdy bieg i każdy krok do schematu `audit` (tabele `audit.EtlRun` i `audit.EtlStep`) - status (`SUCCESS/PARTIAL/FAILED/SKIPPED`), czas trwania, liczby wierszy oraz ewentualne komunikaty błędów. Widok `audit.vLastRun` udostępnia podgląd ostatniego biegu. Skrypt tworzący schemat: `sql_help/Audit_setup.sql`.
- **Parametryzacja**: pakiety SSIS używają parametrów projektu (`ServerName`, `DatabaseName`, `PythonExe`, `ScriptsDir`) podpiętych wyrażeniami, a skrypty Python - zmiennych środowiskowych (`POWERDWH_SERVER`, `POWERDWH_DATABASE`). Dzięki temu przeniesienie rozwiązania na inną maszynę sprowadza się do zmiany wartości w jednym miejscu, bez edycji kodu pakietów.

6.7 Kontrola jakości danych

Kontrola jakości realizowana jest dwoma skryptami SQL:

- `DataQuality_checks.sql` - framework reguł w wymiarach: Kompletność, Unikalność, Poprawność, Spójność i Aktualność. Wyniki zapisywane są do tabeli `dq.CheckResults` z automatycznym statusem PASS/FAIL i numerem uruchomienia (`RunId`). Reguły obejmują m.in. unikalność kluczy faktów, integralność referencyjną `TimeId/PowerPlantId`, poprawność SCD2 oraz zakresy fizyczne miar pogodowych.
- `PostLoad_checks.sql` - szybki test po załadowaniu: liczby wierszy, zakres dat, świeżość każdego faktu względem dnia poprzedniego (z tolerancją na kilkudniowy lag Meteostatu dla `FactWeather`), wykrywanie brakujących dni i dni o nietypowej liczbie kwadransów oraz elektrownie ze staging niedopasowane do wymiaru.

Kontrola jakości jest uzupełniona o audyt techniczny procesu ETL (schemat `audit`, sekcja 6.7 wyżej w opisie orkiestracji), który rejestruje przebieg każdego biegu i pozwala powiązać wyniki reguł jakości z konkretnym uruchomieniem ładowania.

6.8 Test poprawności działania na danych syntetycznych

Aby udowodnić poprawne działanie hurtowni *niezależnie* od dostępności źródeł zewnętrznych (PSE, Meteostat), Pythona i SSIS, przygotowano samodzielny skrypt testowy `sql_help/SyntheticData_test.sql`. Skrypt wstrzykuje deterministyczne dane syntetyczne, sprawdza wynik kluczowych mechanizmów ETL i na końcu wszystko wycofuje (`ROLLBACK`), nie pozostawiając śladu w bazie. Wyniki gromadzone są w zmiennej tabelarycznej, która celowo nie podlega wycofaniu, dzięki czemu raport przeżywa cofnięcie danych. Każda asercja kończy się statusem PASS lub FAIL. Test obejmuje sześć obszarów:

- **SCD typu 2** - dla istniejącej, aktywnej wersji elektrowni zmiana kategorii i mocy w staging powoduje zamknięcie starej wersji (`isValid=0`, ustawione `validTo`) i otwarcie nowej; weryfikowana jest dokładnie jedna aktywna wersja oraz brak nakładających się okresów. Test wywołuje *rzeczywistą* procedurę `etl.usp_Load_DimPowerPlant`;
- **Zmiana czasu (DST)** - dwa pomiary dla tej samej ściany zegara w dniu jesiennej zmiany czasu (godzina zwykła i powtórzona) trafiają na dwa odrębne `TimeId` (różniące się bitem `isExtraHour`) i pozostają osobnymi wierszami faktu - dowód, że model nie skleja powtórzonej godziny;
- **Idempotencja** - dwukrotne załadowanie tego samego okna metodą `DELETE-okno + INSERT` nie tworzy duplikatów (liczba wierszy pozostaje stała);
- **Integralność referencyjna** - próba wstawienia faktu z nieistniejącym `TimeId` jest odrzucana przez klucz obcy na poziomie bazy;
- **Kontrola jakości - test pozytywny** - na czystych danych syntetycznych reguły jakości nie zgłaszają żadnych naruszeń;
- **Kontrola jakości - test negatywny** - celowo wstrzyknięte błędy (temperatura poza zakresem fizycznym, ujemne zapotrzebowanie, duplikat klucza faktu, produkcja przekraczająca moc zainstalowaną, nakładające się wersje SCD) są przez reguły wykrywane. To dowodzi, że kontrole nie są „puste” - faktycznie reagują na złe dane.

Uruchomienie testu na wczytanej bazie zakończyło się wynikiem **16/16 PASS**. Pełny wynik przedstawia tabela 8.

Lp	Obszar	Weryfikowana właściwość	Wynik
1	SCD2	po zmianie istnieje dokładnie jedna aktywna wersja	PASS
2	SCD2	aktywna wersja ma nowe atrybuty i <code>validTo = NULL</code>	PASS
3	SCD2	stara wersja zamknięta (<code>isValid=0</code> , <code>validTo>validFrom</code>)	PASS
4	SCD2	brak nakładających się okresów wersji	PASS
5	DST	powtórzona godzina = dwa odrębne wiersze faktu	PASS
6	DST	dwa różne <code>TimeId</code> dla tej samej ściany zegara	PASS
7	DST	<code>DimTime</code> : znacznik <code>isExtraHour</code> zgodny z bitem <code>TimeId</code>	PASS
8	Idempot.	ponowny bieg nie tworzy duplikatów (liczba stała)	PASS
9	Ref. int.	FK odrzuca fakt z nieistniejącym <code>TimeId</code>	PASS
10	DQ (+)	czyste dane: brak duplikatów produkcji	PASS
11	DQ (+)	czyste dane: brak wielu aktywnych wersji elektrowni	PASS
12	DQ (-)	wykryto temperaturę poza zakresem fizycznym ($>45^{\circ}\text{C}$)	PASS
13	DQ (-)	wykryto ujemne zapotrzebowanie (<code>load_actual<0</code>)	PASS
14	DQ (-)	wykryto duplikat klucza (<code>PowerPlantId,TimeId</code>)	PASS
15	DQ (-)	wykryto produkcję przekraczającą moc zainstalowaną	PASS
16	DQ (-)	wykryto nakładające się wersje SCD	PASS

Table 8: Wynik testu poprawności działania na danych syntetycznych (`SyntheticData_test.sql`)

6.9 Podsumowanie mapowań STTM

Logika mapowania pól źródłowych na docelowe jest zaimplementowana w skryptach ekstrakcji oraz w procedurach/transformacjach ładowania. Poniższa tabela podsumowuje najważniejsze reguły.

Tabela docelowa	Źródło	Pole źródłowe	Reguła ETL
<code>DimPowerPlant</code>	PSE gen-jw + <code>powerplant_meta.csv</code>	nazwa, kategoria, moc, lokalizacja	utworzenie/aktualizacja rekordu SCD2 na podstawie nazwy jako klucza biznesowego
<code>DimTime</code>	generator kalendarza	timestamp	wygenerowanie atrybutów kalendarzowych oraz flag weekendu i zmiany czasu
<code>FactWeather</code>	Meteostat	<code>temp</code> , <code>dwpt</code> , <code>rhumb</code> , <code>prcp</code> , <code>wdir</code> , <code>wspd</code> , <code>pres</code> , <code>coco</code>	kopiowanie pól pogodowych, lookup czasu i elektrowni
<code>FactPowerPlantOutput</code>	PSE gen-jw	<code>value</code>	agregacja produkcji po elektrowni i kwadransie
<code>FactPolandEnergy</code>	PSE <code>energy-prices</code> , <code>rce-pln</code> , <code>kse-load</code>	ceny, bilans, <code>load forecast</code> , <code>load actual</code>	agregacja do kwadransa; średnia dla cen i zapotrzebowania, suma dla bilansu

Table 9: Skrócone mapowanie STTM

7 Kluczowe miary i atrybuty w modelu

7.1 Miary pogodowe

- `temp` - temperatura powietrza w stopniach Celsjusza,
- `dew_point` - punkt rosy,
- `relative_humidity_pct` - wilgotność względna w procentach,
- `precipitation` - opad w mm,
- `wind_direction`, `wind_speed` - kierunek i prędkość wiatru,
- `pressure` - ciśnienie atmosferyczne,
- `weather_code` - kod zjawiska pogodowego.

7.2 Miary produkcyjne

- `Power` - produkcja elektrowni w danym kwadransie,
- `installed_power` - moc zainstalowana elektrowni, atrybut wymiaru i podstawa do obliczania wykorzystania mocy,
- miara raportowa **Współczynnik wykorzystania** (Capacity Utilization) = `Power` / `installed_power`, zaimplementowana w Power BI,
- miary raportowe **Moc floty** oraz **Średnia moc** (w przekroju kraju i województwa) używane na stronach Przegląd, Rynek i bilansowanie oraz Geografia i moce,
- agregacja produkcji według kategorii elektrowni, województwa i czasu zrealizowana w raporcie.

7.3 Miary krajowe i cenowe

- `cen_cost` - cena energii bilansującej,
- `cor_cost` - cena rezerwy operacyjnej,
- `ceb_sr_cost` - średnia ważona cena energii bilansującej,
- `sk_cost_power` - koszt rezerwy mocy,
- `cdsac_cost` - cena energii z rynku Single Day-Ahead Coupling w PLN/MWh,
- `balance_power` - bilans mocy krajowego systemu,
- `rce_cost` - rynkowa cena energii,
- `load_fcst` - prognozowane zapotrzebowanie KSE,
- `load_actual` - rzeczywiste zapotrzebowanie KSE,
- miara raportowa **Błąd prognozy (MW)** (Forecast Error) = `load_actual` - `load_fcst`, zaimplementowana w Power BI i prezentowana na stronie Ceny i bilans w przekroju godzin,
- analogiczna miara względna **Błąd prognozy %** = $(\text{load_actual} - \text{load_fcst}) / \text{load_actual}$.

7.4 Kluczowe atrybuty analityczne

- atrybuty czasu: rok, kwartał, miesiąc, tydzień, dzień, godzina, kwadrans, dzień tygodnia, weekend,
- atrybuty zmiany czasu: dodatkowa godzina i brakująca godzina,
- atrybuty elektrowni: nazwa, kategoria, województwo, współrzędne geograficzne, zainstalowana moc,
- atrybuty historyczne SCD2: data ważności rekordu, data końca ważności i flaga aktywności rekordu.

8 Raporty dla użytkowników (Power BI)

Warstwa raportowa została zaimplementowana w pliku `business.pbix` jako siedem powiązanych stron. Model danych w Power BI odwzorowuje konstelację faktów z hurtowni i jest uzupełniony o dwie tabele pomocnicze: **Paliwa** (grupowanie kategorii elektrowni: Biomasa, Fotowoltaika, Gaz ziemny, Węgiel brunatny, Węgiel kamienny, Woda) oraz **Czynnik pogodowy** (tabela miar DAX, m.in. **Współczynnik wykorzystania** i **Błąd prognozy (MW)**). Nawigację ułatwiają wspólne fragmentatory (zakres dat, kategoria elektrowni). Poniżej opisano poszczególne strony wraz z tytułami wizualizacji.

8.1 Strona 1: Przegląd

Pulpit wprowadzający z czterema wizualizacjami i fragmentatorem zakresu dat (*Okres*):

- *Produkcja wg Źródła: kraj vs wybrane województwo (mapa + okres)* - wykres kolumnowy łącznej produkcji według rodzaju paliwa (Węgiel kamienny, Węgiel brunatny, Gaz ziemny, Biomasa, Fotowoltaika, Woda) w zestawieniu Polska vs wybrane województwo;
- *Zapotrzebowanie KSE: prognoza vs rzeczywiste* - wykres liniowy `load_actual` i `load_fcst` w czasie;
- *Moc zainstalowana wg województwa i Źródła* - skumulowany wykres słupkowy mocy w podziale na województwo i rodzaj elektrowni;
- *Mapa: Średnia moc wg lokalizacji* - kartogram województw Polski (warstwa GeoJSON).




Figure 3: Power BI - strona *Przegląd* (fragmentator zakresu dat *Okres* w prawym górnym rogu)

8.2 Strona 2: Rynek i bilansowanie

Analiza rynkowa w trzech wykresach liniowych:

- *Ceny i koszty bilansujące w czasie* - składowe cenowe CDSAC, CEB śr., CEN, COR i SK (w PLN);
- *Zapotrzebowanie KSE vs produkcja największych elektrowni* - zapotrzebowanie rzeczywiste zestawione z miarą *Moc floty* (w MW);
- *Rynkowa cena energii (RCE)* - przebieg średniej *rce_cost* w PLN.




Figure 4: Power BI - strona *Rynek i bilansowanie* (wykresy liniowe z hierarchią czasu umożliwiającą drążenie)

8.3 Strona 3: Pogoda a produkcja

Sedno celu biznesowego - dwa wykresy punktowe wiążące produkcję z pogodą:

- *Produkcja a temperatura* (rozmiar = moc zainst., kolor = paliwo) - średnia moc względem średniej temperatury, kolor wg kategorii paliwa, rozmiar punktu wg mocy zainstalowanej;
- *Produkcja a ciśnienie* (kolor = kod pogody) - średnia moc względem średniego ciśnienia, kolor wg kodu zjawiska pogodowego.




Figure 5: Power BI - strona *Pogoda a produkcja* (legendy kategorii paliwa i kodu pogody działają jako interaktywne filtry)

8.4 Strona 4: Ceny i bilans

Powiązania cen z popytem i bilansem (podział *Czy weekend*):

- *Błąd prognozy (MW) wg Godzina* - wykres kolumnowy miary Błąd prognozy (MW) w przekroju godzin doby (największe odchylenia w godzinach okołopołudniowych);
- tabela przestawna średniej RCE w układzie godzina $\times$ dzień tygodnia (z sumami);
- *Średni bilans mocy i średnie rce wg godziny* - wykres punktowy RCE względem bilansu mocy;
- *Zależność średniej prawdziwego obciążenia (MW) i RCE (PLN) wg godziny* - wykres punktowy RCE względem rzeczywistego obciążenia.




Figure 6: Power BI - strona *Ceny i bilans* (podział serii wg legendy *Czy weekend*: Falsz/Prawda)

8.5 Strona 5: Wzorce czasowe

Analiza sezonowości i profili dobowych:

- *Współczynnik wykorzystania w czasie* - wykres kolumnowy miary Współczynnik wykorzystania z hierarchią drążenia miesiąc → tydzień → dzień tygodnia → godzina;
- *Średnia prawdziwego obciążenia [MW] wg Dzień tygodnia* - wykres kolumnowy ujawniający wyższe obciążenie w dni robocze niż w weekend.




Figure 7: Power BI - strona *Wzorce czasowe*. Wykres *Współczynnik wykorzystania w czasie* (u góry, wg miesiąca) ma hierarchię drążenia miesiąc → tydzień → dzień tygodnia → godzina

8.6 Strona 6: Geografia i moce

Ujęcie przestrzenne i porównanie jednostek (fragmentator *Kategoria*):

- *Moc zainstalowana elektrowni wg lokalizacji i paliwa [MW]* - mapa punktowa na podkładzie geograficznym, rozmiar wg mocy zainstalowanej, kolor wg kategorii;
- *Współczynnik wykorzystania wg paliwa* - wykres kolumnowy (najwyższy dla Biomasy, najniższy dla Wody);
- *Moc zainstalowana wg województw i paliwa [MW]* - skumulowany wykres kolumnowy;
- *Średnia produkcja wg elektrowni [MW]* - wykres słupkowy rankingowy (m.in. Bełchatów, Opole, Kozienice 2, Turów, Kozienice 1, Jaworzno 2 JWCD, Gryfino, Połaniec).




Figure 8: Power BI - strona *Geografia i moce* (fragmentator *Kategoria* z wielokrotnym wyborem w lewym dolnym rogu)

8.7 Strona 7: Pogoda a moc (kosze)

Strona analityczna poświęcona bezpośrednio zależności średniej produkcji elektrowni od warunków pogodowych. Zawiera trzy wykresy kolumnowe grupowane (świadomie zamiast wykresów punktowych), w których oś X stanowią przedziały (kosze) wartości pogodowej, legendę - kategorię paliwa, a wysokość słupka - średnią moc:

- Średnia moc wg temperatury (kosze 2 °C) - przedziały temperatury co 2 °C;
- Średnia moc wg punktu rosy (kosze 2 °C) - przedziały punktu rosy co 2 °C;
- Średnia moc wg prędkości wiatru (kosze 1 m/s) - przedziały prędkości wiatru co 1 m/s (oś przycięta do 40 m/s).

Przedziały utworzono mechanizmem grupowania (binning) Power BI. Kluczowym elementem jest autorska miara DAX Średnia moc wg pogody, która za pomocą funkcji `TREATAS` przenosi kontekst pomiaru pogodowego (`TimeId` i `PowerPlantId` z `FactWeather`) na wymiary `DimTime` i `DimPowerPlant`. Dzięki temu średnia z `FactPowerPlantOutput[Power]` reaguje na koszt pogodowy mimo jednokierunkowych relacji między tabelami faktów (bez tego słupki byłyby płaskie - pokazywałyby średnią globalną). Przygotowano także miary odchylenia standardowego i jego granic (`Odch std moc pogoda`, `Moc górna/dolna pogoda`); Power BI nie udostępnia jednak słupków błędów dla wykresu kolumnowego z legendą, więc nie zostały one naniesione. Widoczny jest spadek średniej mocy przy wysokich temperaturach oraz ujemne wartości dla kategorii Woda (praca pompowa elektrowni szczytowo-pompowych). Kosze temperatury i punktu rosy ustawiono na 2 °C (zamiast pierwotnych 0,5 °C) dla lepszej czytelności, a oś prędkości wiatru przycięto do 40 m/s, pomijając wizualnie pojedyncze wartości odstające źródła. Osie opisano jednostkami: oś X - °C (temperatura, punkt rosy) lub m/s (prędkość wiatru), oś Y - MW (średnia moc).




Figure 9: Power BI - strona *Pogoda a moc (kosze)*: średnia moc w przedziałach temperatury, punktu rosy i prędkości wiatru, w podziale na kategorię paliwa

8.8 Interaktywność: fragmentatory i drażenie (drill-down)

Raport jest interaktywny - poniżej zestawiono dostępne opcje wyboru i drażenia oraz miejsca ich występowania:

- **Fragmentator *Okres*** (zakres dat) - strona *Przegląd*, prawy górny róg; ogranicza zakres czasowy wszystkich wizualizacji strony (domyślnie 10.04.2026-13.06.2026).
- **Fragmentator *Kategoria*** (rodzaj elektrowni, tryb *Wiele zaznaczeń*) - strona *Geografia i moce*, lewy dolny róg; pozwala zawęzić analizę do wybranych paliw.
- **Drażenie hierarchii czasu** (drill-down) - wykres *Współczynnik wykorzystania w czasie* (strona *Wzorce czasowe*) oraz wykresy liniowe na stronach *Przegląd* i *Rynek i bilansowanie*: hierarchia miesiąc → tydzień → dzień tygodnia → godzina. Drażenie uruchamia się przyciskami w prawym górnym rogu wizualizacji (strzałka w dół - tryb drażenia, podwójna strzałka - przejście na niższy poziom dla wszystkich kategorii).
- **Podział wg legendy *Czy weekend*** (Fałsz/Prawda) - wykresy punktowe na stronie *Ceny i bilans*; rozróżnia dni robocze i weekend.
- **Interaktywne legendy** - kliknięcie pozycji legendy (kategoria paliwa, kod pogody) wyróżnia wybraną serię na stronach *Przegląd*, *Pogoda a produkcja* i *Geografia i moce*.
- **Filtrowanie krzyżowe (cross-filtering)** - kliknięcie elementu jednej wizualizacji (np. województwa, paliwa lub elektrowni) automatycznie filtruje pozostałe wizualizacje strony; na tej zasadzie działa zestawienie *kraj vs wybrane województwo* na stronie *Przegląd*.

Kontrola jakości i kompletności ładowań realizowana jest w warstwie SQL (tabela `dq.CheckResults` oraz schemat `audit`, sekcja 6.7), niezależnie od raportów analitycznych Power BI.

9 Załączniki

Do raportu dołączone są artefakty implementacji znajdujące się w repozytorium projektu:

- **Skrypt modelu hurtowni:** `sql_help/00_Create_PowerDWH_empty.sql` - baza, schematy `etl/stg`, tabele wymiarów, faktów i staging, klucze obce, indeksy oraz procedura `etl.usp_Load_DimPowerPlant` (jej aktualna wersja również w `SCD_2_DimPowerPlant.sql`).
- **Skrypty kontroli jakości i audytu:** `sql_help/DataQuality_checks.sql`, `sql_help/PostLoad_checks.sql` oraz `sql_help/Audit_setup.sql` (schemat `audit: EtlRun/EtlStep`, widok `vLastRun`).
- **Test poprawności na danych syntetycznych:** `sql_help/SyntheticData_test.sql` - samodzielny, odwracalny (ROLLBACK) test SCD2, obsługi zmiany czasu, idempotencji, integralności referencyjnej oraz wykrywalności reguł jakości (sekcja 6.8).
- **Raport Power BI:** `business.pbix` (siedem stron analitycznych) wraz z plikami granic województw `poland_voivodeships_pl.geojson`.
- **Skrypty ETL (Python):** `extract_powerplant.py`, `extract_poland_energy.py`, `extract_power_output.py`, `extract_weather.py`, `DimTimeloader.py`, `load_range.py` (orkiestrator) oraz `requirements.txt`.
- **Pakiety SSIS:** `Master.dtsx`, `Load_DimTime.dtsx`, `Load_DimPowerPlant.dtsx`, `Load_FactPolandEnergy.dtsx`, `Load_FactPowerPlantOutput.dtsx`, `Load_FactWeather.dtsx`.
- **Dane referencyjne:** `powerplant_meta.csv`, `DimTime.csv`, pliki GeoJSON województw.